

(Bien) tracer et visualiser des données

François Bouchet
LIP6 / Sorbonne Université
francois.bouchet@lip6.fr


Master AI2D – UE IHM
11 février 2025

Importance de la visualisation de données

- “Data is the oil of the 21st century... and analytics is the combustion engine”
[Gartner, 2010]
- “The ability to take data – to be able to **understand** it, to process it, to **extract value** from it, to visualize it, to **communicate** it – that’s going to be a hugely important skill in the next decades.”
[Hal Varian, chief economist at Google, 2009]
- “Data visualization is going to change the way our analysts work with data. They’re going to be expected to respond to issues more rapidly. And they’ll need to be able to dig for more insights – look at data differently, more imaginatively. **Data visualization will promote that creative data exploration.**”
[Simon Samuel, head of customer value modelling for a large bank in UK]


Comment efficacement visualiser ?

- Comment les humains peuvent-ils...
 - Accéder efficacement aux données ?
 - Comprendre leur structure ?
 - Faire des comparaisons ?
 - Prendre des décisions ?
 - Extraire des nouvelles connaissances ?
 - Convaincre les autres ?



Pourquoi des représentations visuelles ?


- Prégnance de la vision (sens dominant)
- Capacité humaine à reconnaître facilement des patterns visuels (à double tranchant...)
- Besoin de voir pour comprendre, expliquer, raisonner et décider



Graphique hiérarchique (dendrogramme)

Bibliothèque JS D3


Source : <https://d3-graph-gallery.com/dendrogram>



Graphique en aire

Bibliothèque Python Matplotlib

Source : <https://python-graph-gallery.com/area-fill-between-two-lines-in-matplotlib/>



Carte en hexbin

Bibliothèque R gg2plot

Source : <https://r-graph-gallery.com/329-hexbin-map-for-distribution.html>

Exemple d'apport d'une visualisation

Le cas du “quartet d'Anscombe”

Dataset I		Dataset II		Dataset III		Dataset IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

Question : Qu'est-ce qui distingue ces 4 (petites) distributions (synthétiques) ?

[Source : Anscombe's quartet, Wikipedia]

Exemple d'apport d'une visualisation

Dataset I		Dataset II		Dataset III		Dataset IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89


Moyenne de x : 9.0
Variance de x : 11.0
Moyenne de y : 7.5
Variance de y : 4.1
Corrélation (x,y) : 0.82
Droite de régression : $y = 3 + 0.5 * x$

Conclusion 1 : visiblement identiques, non ?

[Source : Anscombe's quartet, Wikipedia]

Exemple d'apport d'une visualisation

Dataset I		Dataset II		Dataset III		Dataset IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89



Conclusion 2 : ça reste à voir !

[Source : Anscombe's quartet, Wikipedia]

Visualisation d'informations (InfoViz)

- Une définition officielle : “The use of **computer-supported, interactive, visual** representations of **abstract data** to **amplify cognition**” (Card et al., 1999)
- Une analogie pertinente : “The purpose of information visualization is to **amplify cognitive performance**, not just to create interesting pictures. Information visualizations should do for the mind what automobiles do for the feet.” (Card et al., 2008)




Stuart Card

A-t-on attendu l'informatique pour visualiser ?

Exemple historique #1 : la marche de Napoléon sur Moscou

- “Le Meilleur graphique statistique jamais dessiné” (Edward Tufte)
- Informations :
 - Visualisation spatiale ouest-est
 - Taille de l’armée
 - Température
 - Compréhensible “sans texte annexe”



[Charles Minard, 1869]

Carte Figurative des pertes successives en hommes de l'Armée Française dans la campagne de Russie 1812-1813.

Dressée par M. Minard, Inspecteur Général des Ponts et Chaussées en retraite.

Paris, le 20 Novembre 1869.

Les nombres d'hommes présents sont représentés par les largeurs des zones colorées à raison d'un millimètre pour dix mille hommes; ils sont de plus écrits en travers des zones. Le rouge désigne les hommes qui entrent en Russie; le noir ceux qui en sortent. — Les renseignements qui ont servi à dresser la carte ont été puisés dans les ouvrages de M. M. Chiers, de Fèzensac, de Chambray et le journal inédit de Jacob, pharmacien de l'Armée depuis le 28 Octobre.

Pour mieux faire juger à l'œil la diminution de l'armée, j'ai supposé que les corps du Prince Jérôme et du Maréchal Davoust qui avaient été détachés sur Minsk et Mohilow et ont rejoint vers Orscha et Witebsk, avaient toujours marché avec l'armée.





TABLEAU GRAPHIQUE de la température en degrés du thermomètre de Réaumur au dessous de zéro.

Les Cosaques passent au galop le Niemen gelé.




Autog. par Regnier, 8. Par. 5^{te} Marie 5^{te} 6^{te} à Paris.

Imp. Lit. Regnier et Dourdet.


[Charles Minard, 1869]

Exemple historique #2 : The Broadway Street Pump

- *Ou “comment une bonne visualisation peut aider une découverte scientifique / convaincre de sa pertinence”*
- Contexte : épidémie de choléra, Londres, 1854
- Hypothèse de l'époque :
“miasmes dans l'atmosphère”
- Hypothèse alternative du Dr. Snow :
Et si c'était l'eau ?
- Méthodologie :
 - Parler aux residents
 - Identifier la pompe à eau comme source
 - Construire une carte pour visualiser
 - Convaincre de la désactiver



John Snow



■
Cas de choléra

○
Pompe à eau

Source : https://en.wikipedia.org/wiki/1854_Broad_Street_cholera_outbreak

[Snow, 1854]

Représentation vs. présentation

- **Représentation** = un système formel par lequel l'information peut être spécifiée

- Ex : le nombre trente-quatre

34
décimal

100010
binaire

XXXIV
romain

- Différentes représentations = différents aspects de l'information (méta-information)

- Décimal :

- Dénombrement
- Importance des puissances de 10 (taille du nombre)


- Binaire :

- Dénombrement
- Importance des puissances de 2

- Romain : être culturellement approprié ou impressionner ses amis 😊


Représenation vs. présentation

- Présentation : comment les éléments sont placés et organisés sur l'écran




Principes d'excellence graphique

- Une présentation soignée de données intéressantes – dépend de :
 - La substance
 - Les statistiques
 - Le design choisi
- Transmet le plus d'informations possibles en un minimum de temps, avec le moins d'encre possible dans le plus petit espace possible
- S'appuie toujours sur des variables multiples
- **Dit la vérité sur les données**



[Tufte, 1983 | 2001 2nd ed.]

Comment obtenir une bonne visualisation ?



- **Sélection** (filtre) : réduction des données à visualiser selon l'utilisateur
- **Représentation** (mapping) : données clés associées à des primitives géométriques (e.g. points, lignes) et leurs attributs (e.g. couleur, position, taille)
- **Présentation** (rendering) : des données géométriques sont converties en une image


Étape la plus critique

Bonne visualisation : points de vigilance

- **Sélectionner** les mauvaises données
- **Filtrer** des données importantes
- Ne pas comprendre le **type de choses à montrer**
- Choisir la **mauvaise représentation**
- Choisir le **mauvais format** de représentation
- Proposer des **interactions inappropriées** pour explorer les données


Exercice : critiquer une visualisation

- À qui s'adresse la visualisation ?
- À quoi permet-elle de répondre ?
- Pourquoi (n')aimez-vous (pas) cette visualisation ?
 - 2 raisons
- Quelles améliorations possibles ?



Source : Wikipedia (modifié)

Exercice : quelques alternatives




- + une légende
- + des informations sur les (petits) états
- + le nombre de grands électeurs

- pas de prise en compte des densités de population
- pas de prise en compte du nombre de grand électeurs dans la visualisation

Source : Wikipedia (original)

https://en.wikipedia.org/wiki/2024_United_States_presidential_election


Exercice : quelques alternatives



- + granularité plus fine
- + prise en compte de l'écart
(+ foncé = + grand)


- géographie supposée connue

Exercice : quelques alternatives




- + information clé en haut
- + poids respectif des états visible
- + densité de population visible
- + états nommés = pivots + "connus"
- pas d'information sur la répartition du vote intra-état ou les écarts

Exercice : quelques alternatives



- + noms des états
- + nombres de grands électeurs
- + visualisation alternative permettant de voir qui gagne
- + proportionnalité des taille d'états avec poids électoral reel
- + maintien de la topographie générale

Exercice : quelques alternatives



- perte de la géographie
- + information
- + focus sur les écarts inter-élections

Lean Democrat			
	DEM.	REP.	% EXP.
Maine	52%	45%	99%
N.H.	51%	48%	100%
N.M.	52%	46%	100%
Va.	52%	46%	99%

Competitive			
	DEM.	REP.	% EXP.
Minn.	51%	47%	100%
Ariz.	47%	52%	100%
Ga.	49%	51%	100%
Mich.	48%	50%	100%
Nev.	47%	51%	100%
Pa.	49%	50%	99%
Wis.	49%	50%	100%
N.C.	48%	51%	99%

Lean Republican			
	DEM.	REP.	% EXP.
Fla.	43%	56%	100%
Texas	42%	56%	99%

Solid Democrat			
	DEM.	REP.	% EXP.
Calif.	58%	38%	99%
Colo.	54%	43%	98%
Conn.	56%	42%	99%
D.C.	90%	6%	100%
Del.	57%	42%	100%
Hawaii	61%	37%	100%

Solid Republican			
	DEM.	REP.	% EXP.
Alaska	41%	55%	99%
Ala.	34%	65%	100%
Ark.	34%	64%	100%
Iowa	43%	56%	100%
Idaho	30%	67%	100%
Ind.	40%	59%	99%

- + classification préalable
- + couleur renforce les chiffres


Source : BBC.com

<https://www.bbc.com/news/election/2024/us/results>

Voir aussi (pour 2016/2020) : <https://explore.votehub.com/>


Limites humaines dans la perception visuelle : luminosité

- La **luminance** (cd/m^2) est objective
- La **luminosité** est subjective (pas d'unité)




*Les deux cercles
sont physiquement
les mêmes*

Limites humaines dans la perception visuelle : luminosité



Limites humaines dans la perception visuelle : luminosité





Illusion de White :


*A, entouré par du noir,
semble plus clair que B*

Limites humaines dans la perception visuelle : couleurs

- Les descriptions objectives : modèle TSL (HSB en anglaise)
 - Teinte (Hue) : la couleur perçue (rouge, vert, bleu...)
 - Saturation : le degré de différence par rapport au gris neutre
 - Luminosité : l'intensité de la couleur



Limites humaines dans la perception visuelle : couleurs



Actual color names
if you're a girl ...

Actual color names
if you're a guy ...




[xkcd, 2010]

<https://blog.xkcd.com/2010/05/03/color-survey-results/>


Quelles couleurs pour visualiser ?

- À éviter mais très courante : l'échelle arc-en-ciel



Source : alamyimages.fr

- Ordre par longueur d'onde n'est pas perceptuel !



[Borland & Russell, 2007]:
Rainbow Color Map (still) considered harmful
<https://ieeexplore.ieee.org/document/4118486>

Quelles couleurs pour visualiser ?

- Quelques règles :
 - Avoir un bon contraste entre fond et objets représentés (background/foreground)
 - N'utiliser que quelques couleurs distinctes (plutôt 5 que 12)

[Ware, 2019]: Information Visualization

Comprendre le type de ses variables

- Type au sens statistique et non informatique 😊
- Échelle de mesure des variables (par ordre croissant d'information) :
 - **Nominale / catégorielle** : pas d'ordre
e.g. cours suivi, genre, URL...
 - **Ordinale** : ordre
e.g. classement à un examen, faible / moyen / élevé...
 - **Intervalle** : ordre et intervalles égaux sur une échelle
e.g. tranches de 10%
 - **Ratio** : ordre, intervalles égaux sur une échelle, et existence d'un zéro
e.g. nombre d'enfants, revenu, temps de réaction...



Quantitative

Quelles couleurs pour visualiser des catégories ?

- Quelques règles :
 - Avoir des noms clairement distincts



- Utiliser des conventions culturelles ou symboliques


Fruits	Brands
 Apple	 Apple
 Banana	 AT&T
 Blueberry	 Home Depot
 Cherry	 Kodak
 Grape	 Starbucks

[Lin et al., 2013]

- Attention aux juxtapositions 2 à 2


Quelles couleurs pour visualiser des échelles (O|I|R) ?

- Quelques règles :
 - Varier luminosité en plus de couleur
 - Échelles de gris ou d'une couleur unique sont plus simples




Source : <https://matplotlib.org/stable/users/explain/colors/colormaps.html>

- Pour des échelles divergentes (valeur centrale et extrêmes), utiliser une couleur claire et désaturée pour le centre, des couleurs sombres pour les extrémités



Dernier point d'attention sur les couleurs



[Test d'Ishihara]

7% des personnes ne verront pas la différence entre vert et rouge !

Que faire varier d'autre ?

Quantitative		Ordinal		Nominal
Position	————	Position	————	Position
Length		Density		Color Hue
Angle		Color Saturation		Texture
Slope		Color Hue		Connection
Area		Texture		Containment
Volume		Connection		Density
Density		Containment		Color Saturation
Color Saturation		Length		Shape
Color Hue		Angle		Length
Texture		Slope		Angle
Connection		Area		Slope
Containment		Volume		Area
Shape	————	Shape		Volume


Hypothèses
(plutôt logiques)

[Mackinlay, 1986]

Que faire varier d'autre ?

- Travaux de Cleveland (1980s)
 - Expériences contrôlées pour déterminer la capacité à percevoir les changements dans des représentations visuelles
 - Variables considérées :
 - Angle
 - Surface
 - Teinte
 - Saturation
 - Densité
 - Longueur
 - Position
 - Angle
 - Volume


Quelques exemples de variations (Cleveland)



Evitons les diagrammes circulaires !

Quelques exemples de variations (Cleveland)


- What percentage in value is the right from the left?



100%

60%

- What percentage in value is the right from the left?




100%

66%

Evitons de jouer sur la teinte quand on veut être précis !

Quelques exemples de variations (Cleveland)


What percentage in size is the right from the left?



100%

52%

What percentage in size is the right from the left?



100%

36%

Evitons de jouer sur la surface quand on veut être précis !

Quelques exemples de variations (Cleveland)

What percentage in
size is the right from the left?




100%




40%

Evitons la 3D pour exprimer une variation linéaire !

Conclusions de Cleveland




A few more (classic) guidelines!



Good reference: *How to Lie with Statistics*, by Darrell Huff (1954)

Chart Rules


- Provide a proper baseline



A 10% increase. Good!



Already looks more impressive



Wow!

Chart Rules

- Provide a **proper baseline** & **label your axes**





Chart Rules

- Provide a **proper baseline** & **label your axes**
- Avoid **eye-candy**



Actual data



The same data with eye-candy & no numbers ... but at least it tells the same general story.



Impressive, but a lie!

Chart Rules

- Provide a **proper baseline** & **label your axes**
- Avoid **eye-candy**
- Avoid **area comparisons** whenever possible




Chart Rules

- Provide a **proper baseline & label your axes**
- Avoid **eye-candy**
- Avoid **area comparisons** whenever possible
- Provide **legends**






Chart Rules

- Provide a **proper baseline & label your axes**
- Avoid **eye-candy**
- Avoid **area comparisons** whenever possible
- Provide **legends**
- **Grids help** – but make them subtle
(about 20% opacity – **no black lines**)



Comment choisir la bonne visualisation ?



- 1) Connaître le type des variables d'intérêt
- 2) Connaître leurs propriétés (ordonnées ou non, nombreuses ou non...)
- 3) Connaître leurs liens éventuels (1 à 1, plusieurs à 1, imbriquées...)
- 4) Utiliser un arbre de decision approprié !

Source : <https://www.data-to-viz.com>

Mais d'où viennent ces données quand on est en interaction ?

Où stocker les données ?

- Nature du stockage :
 - Fichier log
 - Structure : CSV, XML, JSON...
 - Sémantique ?
 - Format propriétaire ou ouvert ?
 - Base de données
 - Structurée (e.g. MySQL)
 - NoSQL (e.g. MongoDB)
- Lieu du stockage :
 - Localement avec/sans synchronisation vs. serveur distant

D'où viennent les données ?

- Données d'interaction
 - ENT (e.g. Moodle)
 - Applications compatibles IMS-LTI (Learning Tools Interoperability) pour intégration dans un LMS (I/O : ID, résultat)
 - Capteurs (à transformer)

- Mais aussi :
 - Historique scolaire
 - Données démographiques (e.g. questionnaires)
 - Observations (à coder par des humains)

Que tracer ?

- Les interactions de l'utilisateur avec l'environnement
- L'état de l'utilisateur
- L'état de l'environnement
- Les rétroactions du système

Quelle standardisation ?

- Du côté des jeux... pas grand chose !
(niveau éditeur ou plateforme de distribution
[Steam, Epic Store...])
- Du côté de l'éducation, besoin
d'interopérabilité plus fort – 2 formats
(compatibles) depuis quelques années :
 - xAPI / TinCan (ADL - DoD)
 - Caliper (consortium IMS)




Principes

- Collecter les données **avec un but**
- Ensemble de “statements” – origine :
 - Actions en ligne
 - Interactions IoT (e.g. “visiter la bibliothèque”)
 - Interactions monde réel (e.g. flash QR code)
- Learning record store (LRS) = surcouche base de données avec format standard et outils de visualisation
- Fonctions associées à des actions pour créer un statement dans le LRS

Qu'est-ce qu'un LRS ?

- Un serveur (i.e. un système capable de recevoir et traiter des requêtes webs) responsable de la réception, du stockage et de l'accès à des "learning records"
(source : ADL – consortium auteur de xAPI)

- Stockage de traces



- Visualisation de traces
 - Brutes (1)
 - Indicateurs (2)
 - Tableau de bord (3)



Différents types de LRS

- LRS orientés “data storage”
 - Enregistrent les données et peuvent les échanger avec d’autres systèmes
 - Services payants ou open source (e.g. Learning Locker)
- LRS “embarqués” dans un système (LMS – ex : Moodle) : accès partiel à la base de traces
- LRS orientés “learning analytics” : permettent construction de dashboards
- Liste de LRS existants :
<https://adlnet.gov/assets/uploads/ChoosingAnLRS.pdf>

Architecture du LRS

- LRS = ensemble d'organisations distinctes
- Dans une organisation :
 - STORE : espace de stockage (= un système observable, e.g. un jeu)
 - CLIENT : système qui a le droit d'écrire des traces dans un store
- Une base d'utilisateurs (USER) pouvant accéder/créer des organisations, STOREs et CLIENTs

Qu'est-ce qu'un "statement" ?

- Triplet (acteur, prédicat, objet) :

```
("http://androide.lip6.fr/button_example",  
"viewed",  
"mailto:test@Sorbonne-universite.fr"  
)
```

- Principe dérivé des triplets RDF (Resource Description Framework) du web sémantique
- Liste des verbes (non limitative) : <https://registry.tincanapi.com/#home/verbs>
- Des extensions existent (communautés de pratiques), en particulier game-based learning : <https://gblxapi.org>
Intégrable à Unity : <https://github.com/gblxapi/UnityGBLxAPI/wiki>
- Un statement est généralement associé à une action (programmation événementielle)
- Pas besoin d'être programmeur pour écrire un statement (format JSON)

Quand	hier à 14h12	Date
Qui	Jean	Acteur
A fait quoi	a répondu	Verbe
Avec quoi	au quiz 2	Objet
Avec quel résultat	avec la note 5	Résultat
Dans quel contexte	depuis son smartphone	Contexte

Que peut-on faire avec ces données ?

RGPD en bref

- General Data Protection Regulation : texte juridique européen
- **Début** : 25 mai 2018
- **But** :
 - protection des données (7 principes à implémenter)
 - protection du droit à la vie privée des individus (8 droits à faciliter)
- Mise en application : “CNIL locales”

Terminologie

- **Données personnelles** : toute information sur un individu qui peut être directement ou indirectement identifié : nom, adresse courriel, données de géolocalisation, ethnicité, genre, données biométriques, convictions politiques ou religieuses, cookies...

/!\ : **pseudonymisation** != **anonymisation**
(réversible) (irréversible)

- **Traitement de données** : toute opération, manuelle ou automatique, de collecte, enregistrement, organisation, structuration, stockage, utilisation, effacement...
- 3 acteurs :
 - Le **sujet des données** (clients, visiteurs)
 - Le **contrôleur des données** (personne décidant quoi en faire)
 - Le **processeur des données** (tierce partie agissant au nom du contrôleur des données – e.g. cloud)

7 principes de protection et de responsabilité des données

1. **Légalité, équité, transparence** (vis-à-vis du sujet)
2. **Limitation du but** : spécifié explicitement au sujet lors de la collecte
3. **Minimisation des données** : pas plus que nécessaire pour le but à atteindre
4. **Précision** : obligation de garder des données à jour
5. **Limitation de stockage** : pas plus longtemps que nécessaire pour le but
6. **Intégrité et confidentialité** : 2FA, crypto de bout-en-bout, formation des employés, 72h si fuite de données
7. **Responsabilité** : le contrôleur des données doit pouvoir démontrer qu'il respecte ces principes (responsabilités attribuées, documentation, contrats avec tiers processeurs de données, existence d'un DPO)

8 droits des sujets des données

1. Droit d'information
2. Droit d'accès
3. Droit de rectification
4. Droit d'effacement
5. Droit de limitation du traitement
6. Droit de portage des données
7. Droit d'objection
8. Droits relatifs à la décision automatique et au profilage

Consentement

- Doit être :
 - Donné librement (13+ ans sinon parent)
 - Spécifique (pas d'autre question – e.g. mailing list)
 - Informé
 - Non ambigu
 - Documenté (garder une trace)
- Sinon impossible de traiter des données personnelles (sauf cas spéciaux : contrats (background check), injonction légale, vie menacée, intérêt public ou « intérêt légitime » n'allant pas contre le droit fondamental des personnes)

Et en science ?

- Plan de gestion des données = réflexion **en amont** :
 - Description des données collectées/créées
 - Standards, formats, méthodologies appliquées
 - Questions éthiques, propriété intellectuelle et restriction (embargo)
 - Prévision pour le partage et l'ouverture
 - Stratégie de préservation à long terme (archivage)
- Des outils d'aide existent : [DMP OPIDoR](#)
- Liens avec problématique [Open Science](#), Open Access...
- Au-delà des données : partage des processus d'analyse (projet ANR [Hubble](#))

“Où trouver des données ?”

- Datasets pour du machine learning (par domaine ou type d'algorithmes) :

- <https://www.kaggle.com/datasets>



- <https://archive.ics.uci.edu/ml/datasets.php>



- Données éducatives (tuteurs intelligents)

- <http://learnsphere.org/>

